Support Vector Machines (SVMs)

Fernando, Julia, Hugo y Mario

UAM

24 de marzo de 2026

Metodología

Nos hemos reunido presencialmente en tres ocasiones:

1. Estudiar la teoría vista en clase y la bibliografía principal (S. Shalev-Shwartz & S. Ben-David (2014), *Understanding Machine Learning: From Theory to Algorithms*) colectivamente.
2. Plantear el trabajo y dividir en temas.
3. Presentar al resto del grupo lo que se ha hecho por separado.

Uso de modelos del lenguaje para programar jupyter notebooks usando las librerías de `sklearn`. Cada uno ha usado el modelo y entorno que ha considerado.

Hard-SVM

Consideramos un problema de clasificación binaria con clases -1 y $+1$.

Sea $D = \{(x_i, y_i)\}_{i=1}^m$ el conjunto de entrenamiento, donde $x_i \in \mathbb{R}^d$, $y_i \in \{-1, +1\}$.

Objetivo: Encontrar un hiperplano que separe las dos clases.

Definición

Decimos que D es **separable por un hiperplano** si existe un hiperplano dado por (w, b) tal que $y_i = sign(\langle w, x_i \rangle + b)$ $\forall i \in \{1, \ldots, m\}$, equivalentemente $y_i(\langle w, x_i \rangle + b) > 0$ $\forall i \in \{1, \ldots, m\}$

<u>Observación:</u> Si D es separable por un hiperplano, hay infinitos hiperplanos separadores.

¿Cómo elegimos el hiperplano óptimo?

Definición

Sea D separable por un hiperplano. Definimos el **margen** de D con respecto a un hiperplano (w, b) (con $\|w\| = 1$) como $\gamma > 0$ tal que $y_i(\langle w, x_i \rangle + b) \geq \gamma \ \forall i \in \{1, \ldots, m\}$

Tomamos el hiperplano separador con mayor margen,

$$\underset{(w,b):\|w\|=1}{\text{arg máx}} \ \underset{i}{\text{mín}} \, |\langle w, x_i \rangle + b| \quad \text{sujeto a} \quad y_i(\langle w, x_i \rangle + b) > 0 \ \forall i$$

Algoritmo Hard-SVM

input: $(x_1, y_1), \ldots, (x_m, y_m)$

solve: $(w_0, b_0) = \arg\text{mín}_{w,b} \|w\|^2$ sujeto a $y_i(\langle w, x_i \rangle + b) \geq 1 \ \forall i$

output: $w = \frac{w_0}{\|w_0\|}$, $b = \frac{b_0}{\|w_0\|}$

Se tiene que $\gamma = \frac{1}{\|w_0\|}$

Support vectors en Hard-SVM

Definición

Llamamos **vectores soporte** a los puntos del conjunto de entrenamiento (x_i, y_i) que cumplen $y_i(\langle w, x_i \rangle + b) = \gamma$

Los vectores soporte "sostienen" al hiperplano, ya que si se mueven o eliminan estos datos el hiperplano cambia. El hiperplano solo depende de estos vectores.

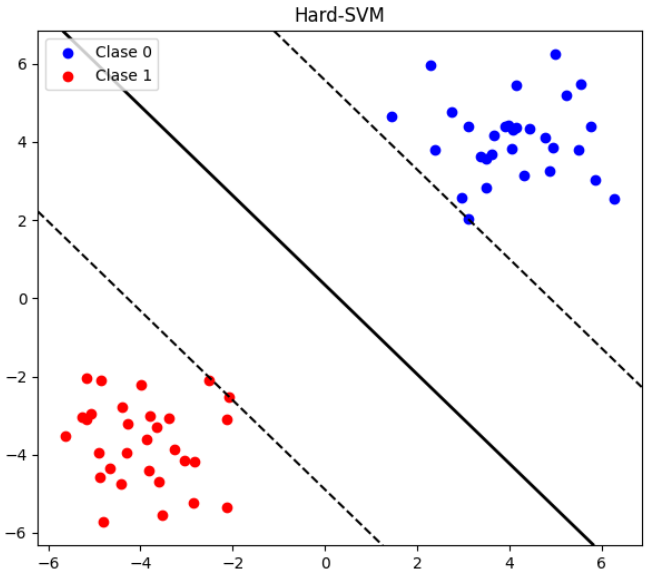

Teorema

Sea w el vector del hiperplano separador óptimo del problema homogéneo ($b = 0$). Sea $I = \{i \in \{1, \ldots, m\} : (x_i, y_i) \text{ es vector soporte}\}$, entonces existen $\alpha_1, \ldots, \alpha_m$ tales que $w = \sum_{i \in I} \alpha_i x_i$

<u>Observación:</u> El problema no homogéneo dado por $D = \{(x_i, y_i)\}$, $x_i \in \mathbb{R}^d$, $y_i \in \{-1, +1\}$ con hiperplano separador (w, b), se puede puede convertir en un problema homogéneo tomando

$$\hat{x}_i = (x_i, 1) \in \mathbb{R}^{d+1} \qquad \hat{y}_i = y_i$$

$$\hat{w} = (w, b) \qquad \hat{b} = 0$$

El hiperplano de margen máximo está determinado exclusivamente por los vectores soporte. Esto hace que el modelo *hard-SVM* sea inestable ya que un pequeño cambio en el conjunto de entrenamiento, como un nuevo dato cerca de la frontera, puede modificar drásticamente el hiperplano solución.

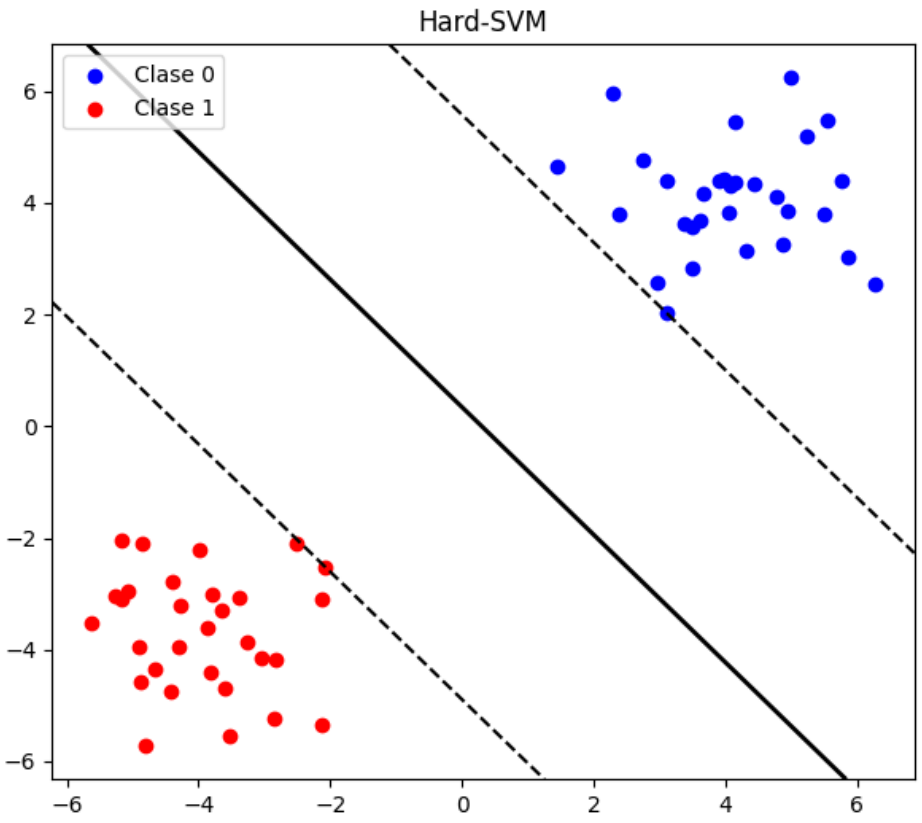

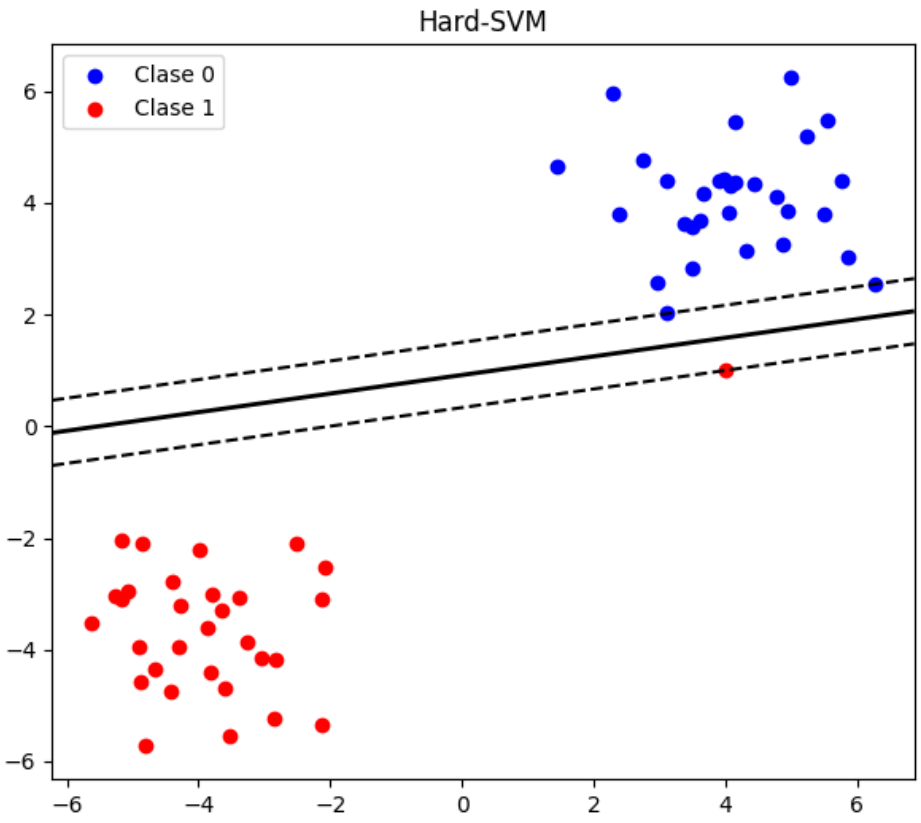

Soft-SVM

Consiste en relajar las condiciones para permitir que se cometan errores al clasificar los datos de entrenamiento. Esto nos permitirá

1. Clasificar conjuntos en los que las clases no sean separables por un hiperplano
2. Evitar el sobreajuste

Introducimos las variables de holgura $\xi_1, \ldots, \xi_m$, $\xi_i \geq 0$

Algoritmo Soft-SVM

input: $(x_1, y_1), \ldots, (x_m, y_m)$

parameter: $\lambda > 0$

solve: $\text{mín}_{w,b,\zeta}(\lambda \|w\|^2 + \frac{1}{m} \sum_{i=1}^{m} \xi_i)$

sujeto a $y_i(\langle w, x_i \rangle + b) \geq 1 - \xi_i$, $\xi_i \geq 0 \ \forall i$

output: w, b

Interpretación de las variables de holgura:

- $\xi_i = 0$: el punto está bien clasificado y fuera del margen.
- $0 < \xi_i < 1$: el punto está dentro del margen, pero bien clasificado.
- $\xi_i > 1$: el punto está mal clasificado.

Interpretación del parámetro λ Controla el equilibrio entre maximizar el margen y permitir errores:

- λ pequeño: penaliza mucho los errores
- λ grande : permite más errores

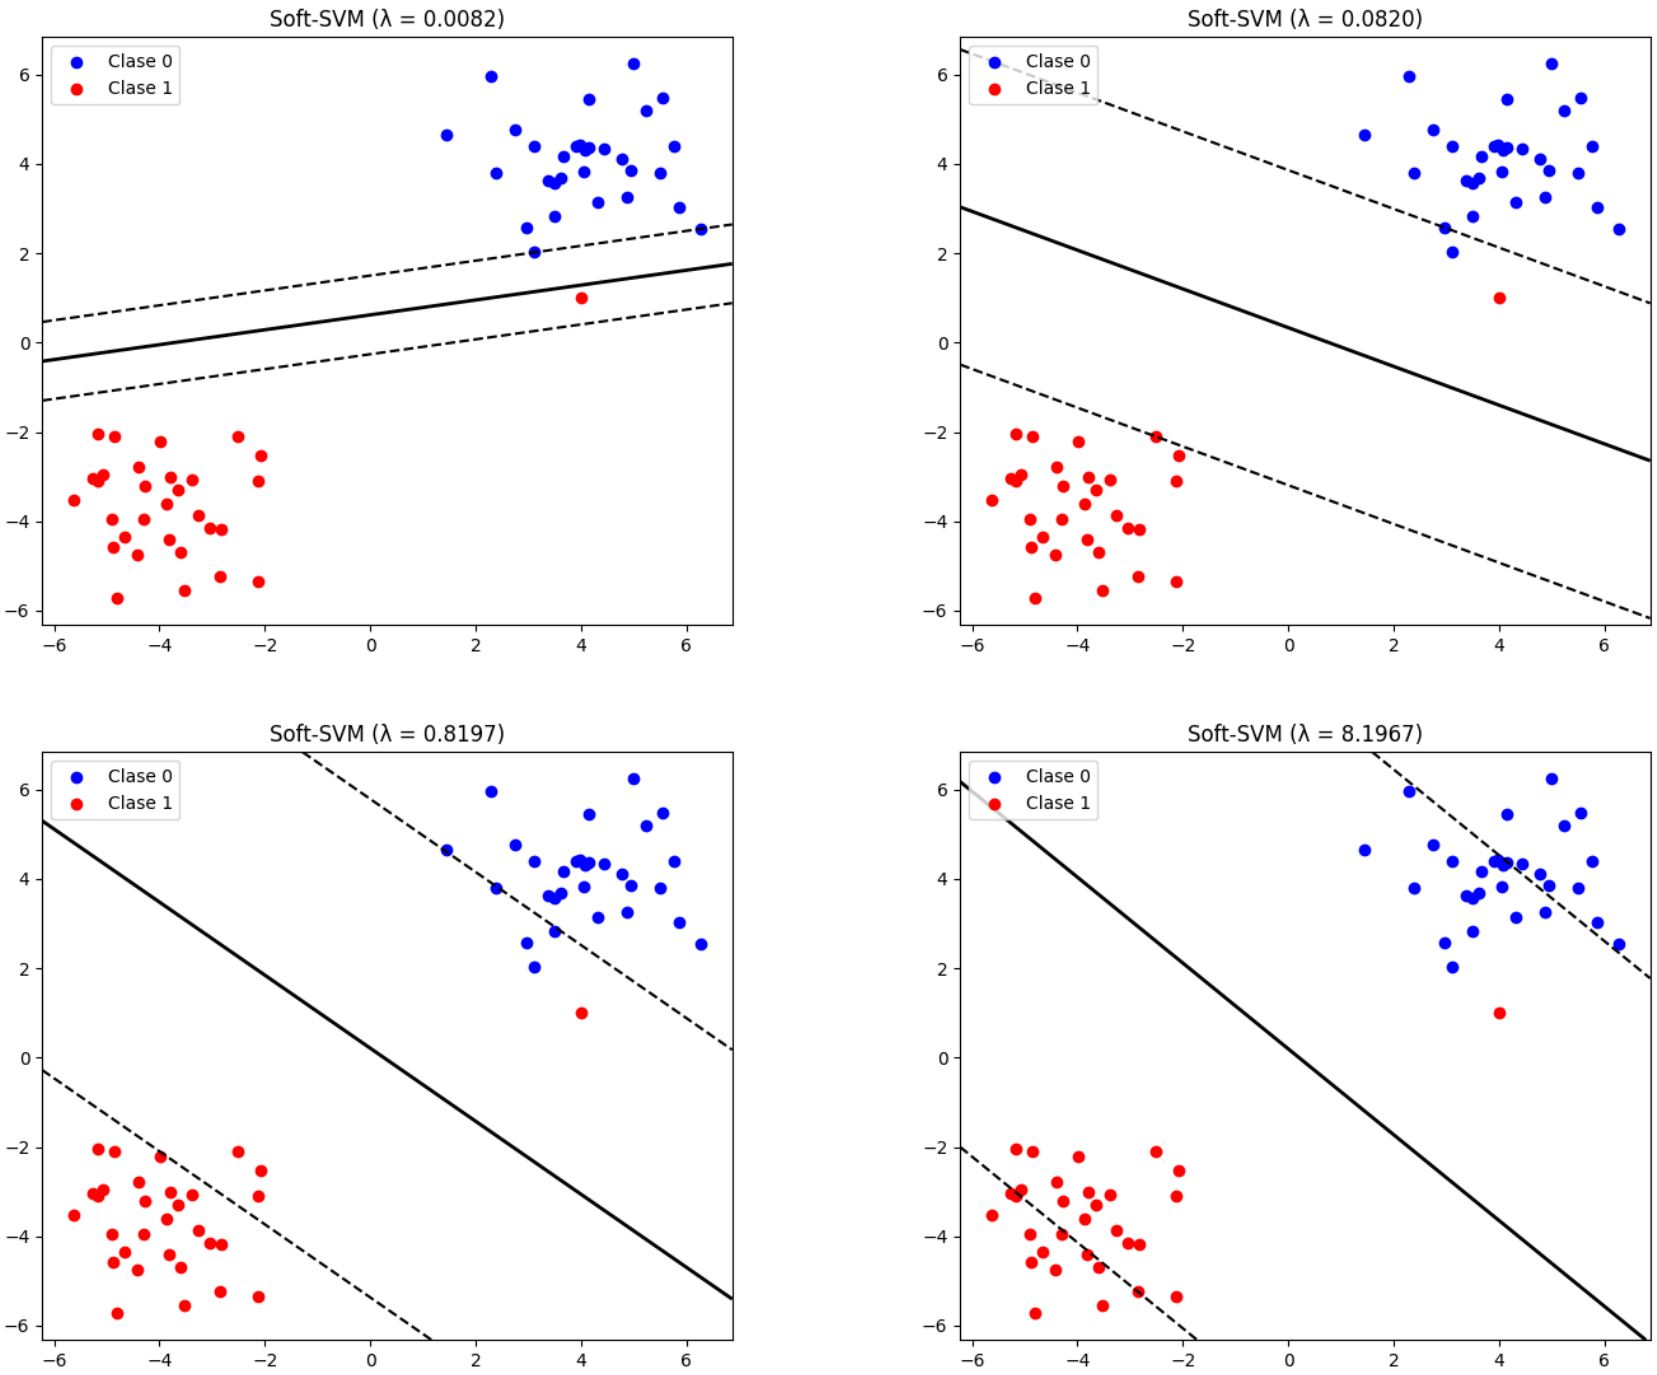
Soft-SVM (λ = 0.0082)
Clase 0
Clase 1
Soft-SVM (λ = 0.0820)
Clase 0
Clase 1
Soft-SVM (λ = 0.8197)
Clase 0
Clase 1
Soft-SVM (λ = 8.1967)
Clase 0
Clase 1

Función de error

$$\mathcal{E}_{\mathcal{D}}^{\text{hinge}}(w,b) := \frac{1}{m}\sum_{i=1}^{m} \text{máx}\{0, 1 - y_i(\langle w, x_i\rangle + b)\}$$

Se tiene que

$$\xi_i := \begin{cases} 0 & \text{si } y_i(\langle w, x_i\rangle + b) > 1 \\ 1 - y_i(\langle w, x_i\rangle + b) & \text{si no} \end{cases}$$

El algoritmo soft-SVM es equivalente a optimizar

$$\underset{(w,b)}{\text{arg mín}} \quad \mathcal{E}_{\text{hinge}}(w,b) + \lambda\|w\|^2$$

<u>Observación:</u>
El error empírico $\mathcal{E}_{\mathcal{D}}(w,b) = \frac{4}{m}\left|\{i : y_i(\langle w, x_i\rangle + b) < 0\}\right|$ no es convexo $\implies$ puede tener varios mínimos.

$\mathcal{E}_{\mathcal{D}}^{\text{hinge}}(w,b) + \lambda\|w\|^2$ es convexa $\forall \mathcal{D}$

Métodos kernel

Si nuestra muestra $\mathcal{D} = \{(y_i, x_i)\}_{i=1}^m$ no es separable y *soft-SVM* no proporciona un resultado satifactorio, podemos incrustar nuestra muestra, mediante una aplicación ϕ, en un espacio de dimensión mayor en el que $\{(y_i, \phi(x_i))\}_{i=1}^m$ sí sea separable.

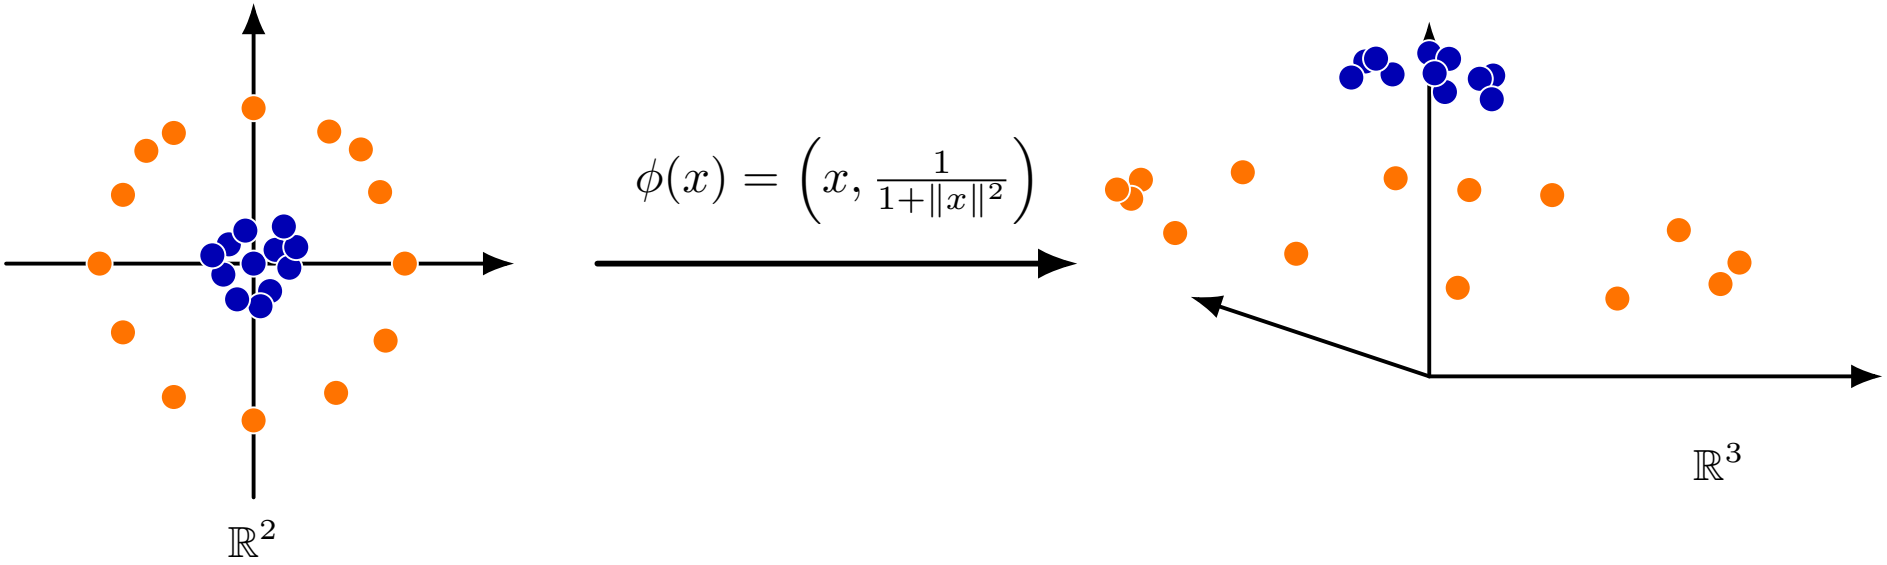

El problema es que no tenemos por qué saber la estructura de los datos y, por tanto, qué ϕ escoger. Para lidiar con esto, usamos la teoría de espacios de Hilbert de núcleo reproductor (RKHS).

- Queremos encontrar $f : X \subset \mathbb{R}^d \to \mathbb{R}^N$ continua.
- Nuestra ϕ será su grafo: $\phi(x) := (x, f(x))$.
- Entonces $K^f(x, y) := \langle x, y \rangle_{\mathbb{R}^d} + \langle f(x), f(y) \rangle_{\mathbb{R}^N}$ es un núcleo de Mercer.
- Además, $K^f(x, y) = \langle \phi(x), \phi(y) \rangle_{\mathbb{R}^d \times \mathbb{R}^N}$.

El siguiente teorema, aunque parezca técnico, nos va a servir para quitarnos la dependencia de ϕ en nuestro algoritmo.

Teorema

Sea

$$\mathcal{H}_\phi := \{\xi : X \to \mathbb{K} \mid \exists w \in \operatorname{span}\{\phi(x)\} : \xi(x) = \xi_w(x) := \langle w, \phi(x)\rangle_{\mathbb{R}^d \times \mathbb{R}^N}\}$$

dotado del producto escalar: $\langle \xi_{w_1}, \xi_{w_2}\rangle_{\mathcal{H}_\phi} := \langle w_1, w_2\rangle_{\mathbb{R}^d \times \mathbb{R}^N}$. Entonces,

$$\mathcal{H}_\phi \equiv \mathcal{H}_{K^f}$$

Demostración. Por construcción, la aplicación

$$\begin{aligned} L : \operatorname{span}\{\phi(x)\} &\longrightarrow \mathcal{H}_\phi \\ w &\longmapsto \langle w, \phi(\cdot)\rangle_{\mathbb{R}^d \times \mathbb{R}^N} \end{aligned}$$

es una isometría lineal biyectiva. Por tanto,

$$\xi(x) = \langle w, \phi(x)\rangle_{\mathbb{R}^d \times \mathbb{R}^N} = \langle L^{-1}\xi, \phi(x)\rangle_{\mathbb{R}^d \times \mathbb{R}^N} = \langle \xi, L\phi(x)\rangle_{\mathcal{H}_\phi} = \langle \xi, K_x^f\rangle_{\mathcal{H}_\phi},$$

que es la propiedad de reproducción. Por unicidad de $\mathcal{H}_{K^f}$, hemos terminado. ■

La aplicación directa de este teorema es que optimizar la aplicación

$$\mathscr{L}_{\mathcal{D}}^{\phi}(w) = \frac{1}{m}\sum_{i=1}^{m} \text{máx}\{0, 1 - y_i\langle w, \phi(x_i)\rangle_{\mathbb{R}^d\times\mathbb{R}^N}\} + \lambda\|w\|^2_{\mathbb{R}^d\times\mathbb{R}^N}$$

sea equivalente a optimizar

$$\mathscr{L}_{\mathcal{D}}^{K}(\xi) = \frac{1}{m}\sum_{i=1}^{m} \text{máx}\{0, 1 - y_i\xi(x_i)\} + \lambda\|\xi\|^2_{\mathcal{H}_K}. \tag{1}$$

El funcional (1) no depende de ϕ, sólo del RKHS elegido. Por tanto, si existen unos espacios $\mathcal{H}_K$ "universales", podremos usarlos para separar de forma satisfactoria nuestra muestra sin tener que escoger de forma arbitraria una aplicación ϕ. Sin embargo, esto introduce un nuevo problema, tenemos que optimizar en un espacio que puede ser de dimensión infinita. Para solventar este inconveniente, usamos el Teorema del representador.

Teorema del representador

Sea K un núcleo de Mercer sobre $X \times X$, $\mathcal{H}_K$ su RKHS asociado y $x_1, \ldots, x_m \in X$. Consideramos el problema

$$\min_{\xi \in \mathcal{H}_K} \frac{1}{m} \sum_{i=1}^{m} \max\{0, 1 - y_i \xi(x_i)\} + \lambda \|\xi\|_{\mathcal{H}_K}^2. \tag{2}$$

Entonces $\exists \alpha_1, \ldots, \alpha_m \in \mathbb{K}$ tales que

$$\xi^*(x) = \sum_{i=1}^{m} \alpha_i K(x_i, x)$$

cumple (2).

Es decir, realmente no estamos optimizando sobre un espacio de dimensión infinita porque se puede encontrar un mínimo en $\operatorname{span}\{K_{x_1}, \ldots, K_{x_m}\}$.

Demostración. Sea $V = \mathrm{span}\{K_{x_1}, \ldots, K_{x_m}\}$. Como V es de dimensión finita, es cerrado y, por tanto, podemos aplicar el teorema de la descomposición ortogonal:

$$\forall \xi \in \mathcal{H}_K \quad \xi = \xi_V + \xi_{V^\perp}$$

Por la propiedad de reproducción,

$$\xi(x_i) = \langle \xi, K_{x_i} \rangle_{\mathcal{H}_K} = \langle \xi_V, K_{x_i} \rangle_{\mathcal{H}_K} = \xi_V(x_i).$$

Además,

$$\|\xi\|^2_{\mathcal{H}_K} = \|\xi_V\|^2_{\mathcal{H}_K} + \|\xi_{V^\perp}\|^2_{\mathcal{H}_K} \geq \|\xi_V\|^2_{\mathcal{H}_K}$$

Entonces,

$$\mathscr{L}^K_{\mathcal{D}}(\xi_V) \leq \mathscr{L}^K_{\mathcal{D}}(\xi).$$

■

Este teorema nos brinda la reformulación definitiva de nuestro problema. Si $\xi \in V_{\mathcal{D}}$, entonces

$$\xi(x_i) = \sum_{j=1}^{m} \alpha_j K(x_i, x_j), \qquad \|\xi\|_{\mathcal{H}_K}^2 = \sum_{i,j=1}^{m} \alpha_i \overline{\alpha}_j K(x_i, x_j).$$

Si definimos $(M_K^{\mathcal{D}})_{i,j} = K(x_i, x_j)$, entonces podemos escribir el funcional a minimizar como:

$$\mathscr{L}_{\mathcal{D}}^K(\alpha) = \frac{1}{m} \sum_{i=1}^{m} \text{máx}\{0, 1 - y_i (M_K^{\mathcal{D}} \alpha)_i\} + \lambda \langle \alpha, M_K^{\mathcal{D}} \alpha \rangle_{\mathbb{K}^m}.$$

Por último, si $\alpha^* = \underset{\alpha \in \mathbb{K}^m}{\arg\,\text{mín}}\, \mathscr{L}_{\mathcal{D}}^K(\alpha)$, el clasificador es

$$f(x) = \text{signo}\left(\sum_{j=1}^{m} \alpha_j^* K(x_j, x) \right).$$

Para terminar, retomamos la discusión sobre los RKHS universales.

Propiedad universal

Decimos que un RKHS es universal si $\forall A, B \subset X$ compactos y disjuntos $\exists f \in$ RKHS tal que $f(A) > 0$, $f(B) < 0$.

Básicamente estamos imponiendo que nuestro espacio sea capaz de separar cualquier muestra. Debido a esto, casi siempre vamos a querer usar núcleos universales en la práctica. Para encontrarlos usamos la siguiente proposición.

Proposición

Sea X un espacio métrico compacto y sea $V \subset C(X)$ un conjunto denso en norma infinito. Entonces V cumple la propiedad universal.

De esta forma se puede demostrar que la función gaussiana de base radial

$$K(x, y) = e^{-\gamma \|x-y\|^2}$$

es un kernel universal si $\gamma > 0$.

Costes Asimétricos: cribado de cáncer de mama

En cribado de cáncer de mama los errores tienen consecuencias diferentes.

Fijamos etiquetas $y \in \{-1, +1\}$:

$$y = +1 \text{ (maligno)}, \qquad y = -1 \text{ (benigno)}.$$

- FP: $y = -1$ y $\hat{y} = +1$ (alarma innecesaria).
- FN: $y = +1$ y $\hat{y} = -1$ (caso clínicamente más grave).

Frente al objetivo estándar (minimizar error 0-1), usamos pérdida coste-sensible:

$$\ell_c(y, \hat{y}) = \begin{cases} 0, & y = \hat{y}, \\ c_{FP}, & y = -1,\ \hat{y} = +1, \\ c_{FN}, & y = +1,\ \hat{y} = -1. \end{cases}$$

Riesgo esperado y coste medio empírico:

$$\mathcal{R}_c(f) = \mathbb{E}[\ell_c(Y, f(X))], \qquad \widehat{\mathcal{R}}_c(f) = \frac{1}{m}\big(c_{FP}\, FP(f) + c_{FN}\, FN(f)\big).$$

En este contexto suele imponerse $c_{FN} > c_{FP}$.

Soft-SVM: efecto de C

Modelo primal de *soft-SVM*:

$$\min_{w,b,\xi} \ \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m}\xi_i \quad \text{s.a.} \quad y_i(\langle w, x_i\rangle + b) \geq 1 - \xi_i,\ \xi_i \geq 0.$$

Notación: salvo constantes de normalización, en `sklearn` se usa $C \propto \frac{1}{\lambda}$.
Margen geométrico: la distancia de un vector soporte a la frontera es $\frac{1}{\|w\|}$.

- $C \uparrow$: se penalizan más las violaciones (ξ_i), suele crecer $\|w\|$ y el margen tiende a estrecharse.
- $C \downarrow$: pesa más la regularización, suele bajar $\|w\|$ y el margen tiende a ampliarse.
- Al variar C, cambian la solución w^* y el conjunto de vectores soporte activos.

Soft-SVM con costes asimétricos: C_+ y C_-

Modelo primal con costes asimétricos:

$$\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C_+ \sum_{i:y_i=+1} \xi_i + C_- \sum_{i:y_i=-1} \xi_i$$

con las mismas restricciones de margen.

- Si $C_+ > C_-$, se penalizan más violaciones en la clase $y = +1$.
- Efecto de $C_\pm$: subir C_+ (o bajar C_-) desplaza la frontera para proteger más a los positivos.
- Efecto típico: disminuyen FN y aumentan FP; lo contrario si se prioriza la clase negativa.

Comparativa visual: $C_+ = 0{,}5$ vs $C_+ = 10$

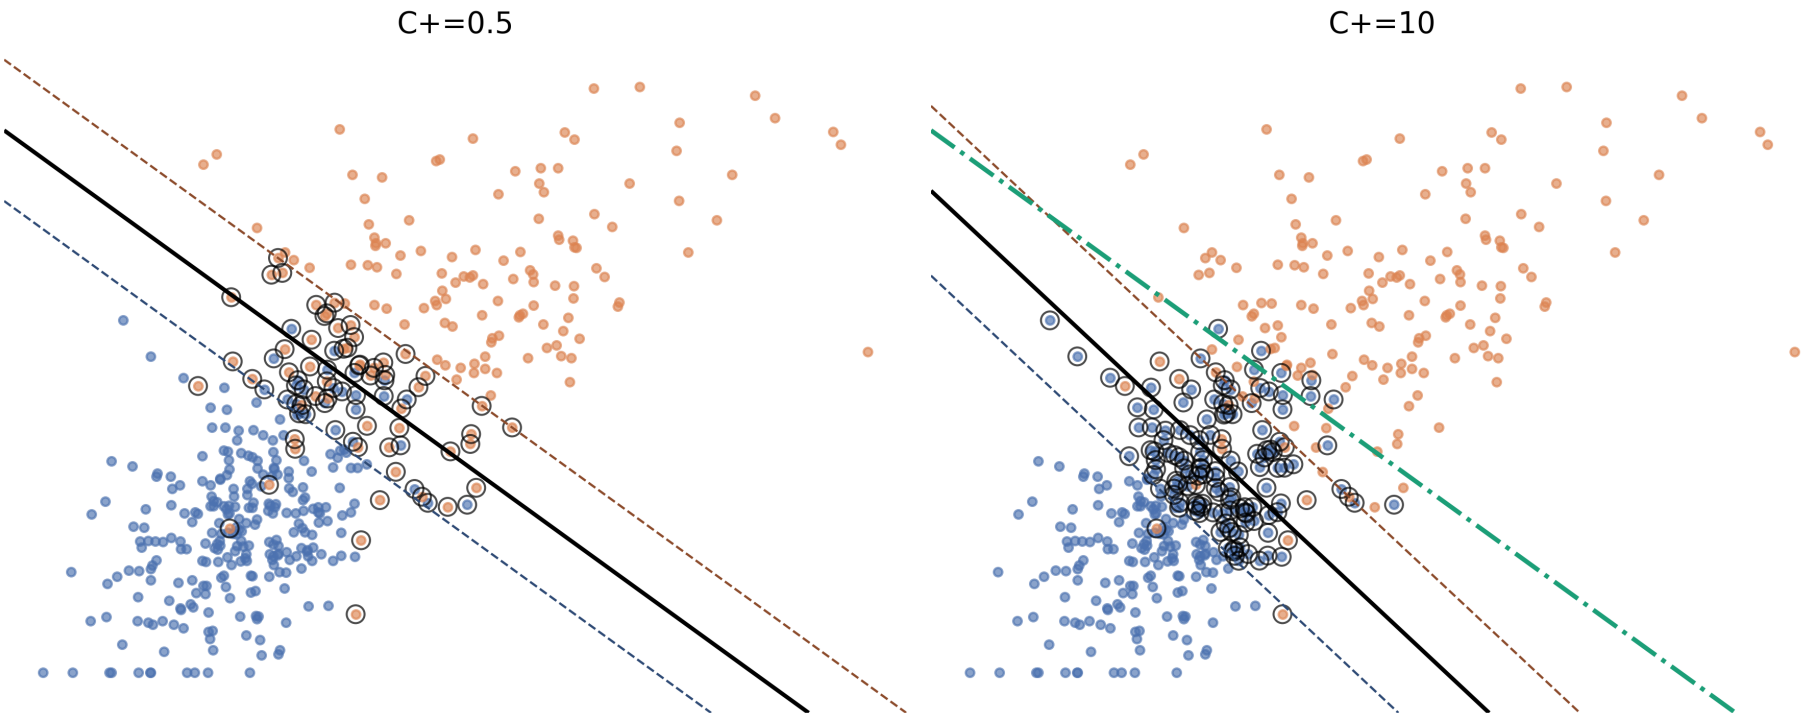

Clasificación lineal multiclase

Podemos extender el algoritmo SVM para clasificar en $k \in \mathbb{N}$ clases. Para $Y = \{1, \ldots, k\}$ y $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^m \subset X \times Y$, definimos:

- **Clasificación:** $f \colon X \to Y$.
- **Error de clasificación:** $\mathcal{E}[f] = \displaystyle\int_X \mathbb{P}(Y \neq f(x) \mid x) \, \mathrm{d}\rho_X(x)$.
- **Error empírico:** $\mathcal{E}_{\mathcal{D}}[f] = \dfrac{1}{m} \left| \{ i \in \{1, \ldots, m\} : f(x_i) \neq y_i \} \right|$.

Tres enfoques para la clasificación multiclase:

1. **One-vs-Rest** (también conocido como One-vs-All).
2. **One-vs-One.**
3. **SVM de Crammer–Singer.**

Reducción al caso binario: One-vs-Rest

Para cada clase $j \in Y$, entrenamos un clasificador binario que distingue la clase j del resto.

1. $\mathcal{D}_j = \{(x_i, \sigma_j(y_i))\}_{i=1}^m$, donde $\sigma_j(y) = \begin{cases} +1 & \text{si } y = j, \\ -1 & \text{si } y \neq j. \end{cases}$
2. Entrenamos un SVM binario en $\mathcal{D}_j$ para obtener $(w_j^*, b_j^*) \in \mathbb{R}^d \times \mathbb{R}$ que definen $\xi_j(x) = \langle w_j^*, x \rangle + b_j^*$.

   Las ξ_j se denominan **funciones de puntuación** o *scores* porque miden la confianza del clasificador en asignar a x la clase j.

La clasificación final es $f(x) = \arg\operatorname*{máx}_{j \in Y} \xi_j(x)$.

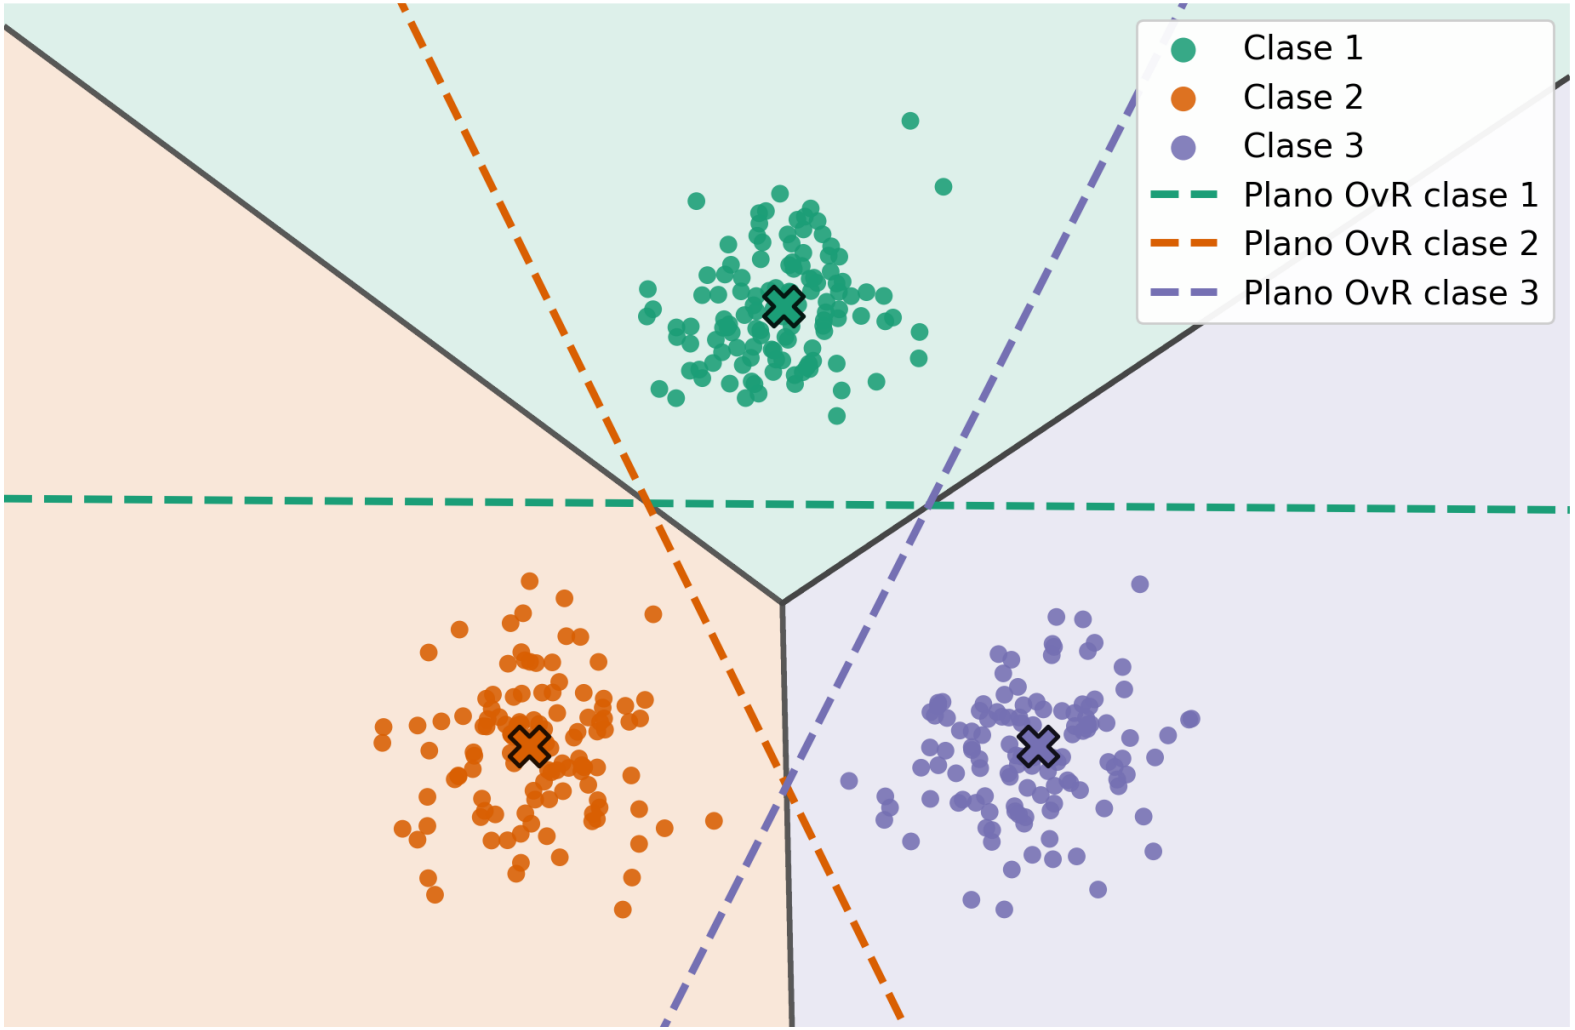

Figura 1: Ejemplo sintético en $\mathbb{R}^2$ y regiones de decisión de una SVM lineal OvR.

Reducción al caso binario: One-vs-One

Para cada par de clases $j, \ell \in Y$ (con $j < \ell$), entrenamos un clasificador binario que distingue entre ellas.

1. $\mathcal{D}_{j\ell} = \{(x_i, \sigma_{j\ell}(y_i)) : i \in I_j \cup I_\ell\}$, donde $I_j = \{i \in \mathbb{N}_m : y_i = j\}$, $I_\ell = \{i \in \mathbb{N}_m : y_i = \ell\}$ y $\sigma_{j\ell}(y) = \begin{cases} +1 & \text{si } y = j, \\ -1 & \text{si } y = \ell. \end{cases}$
2. Entrenamos un SVM binario en $\mathcal{D}_{j\ell}$ para obtener $(w^*_{j\ell}, b^*_{j\ell}) \in \mathbb{R}^d \times \mathbb{R}$ que definen $\xi_{j\ell}(x) = \langle w^*_{j\ell}, x \rangle + b^*_{j\ell}$.

Para clasificar x, cada clasificador binario emite un voto a la clase que predice. La clasificación final es la clase con más votos:

$$f(x) = \arg\max_{j \in Y} \left[\sum_{\ell \in Y \setminus \{j\}} \mathbb{1}_{\{\xi_{j\ell}(x) > 0\}} \right].$$

OvR vs OvO

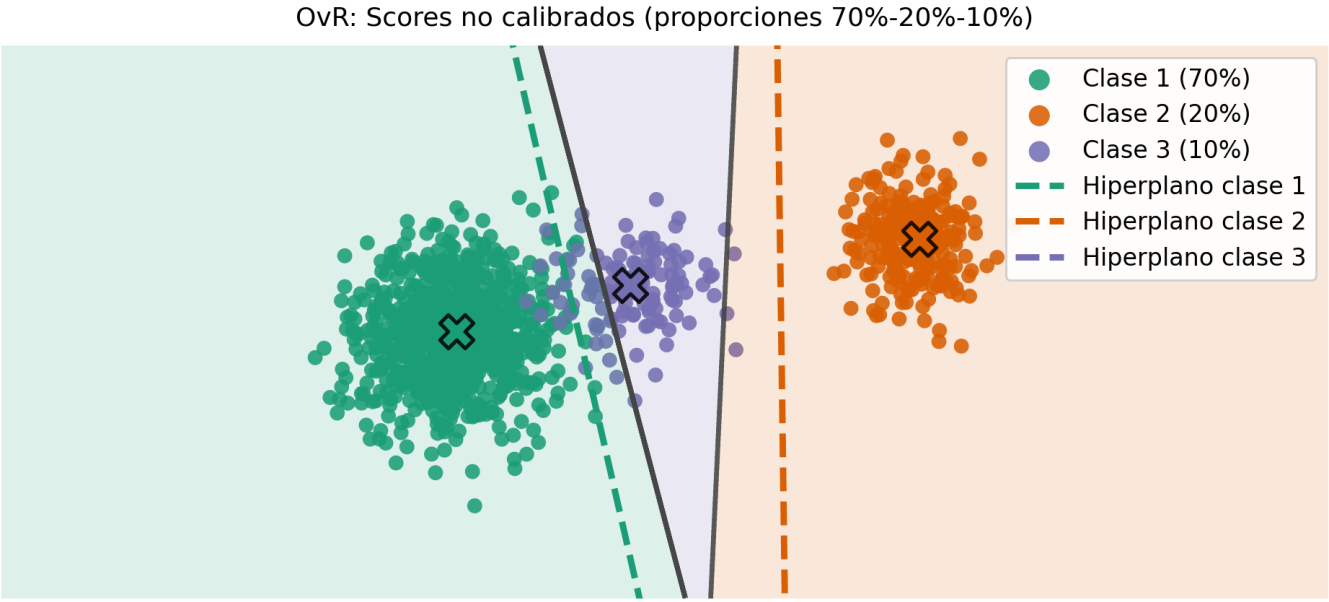
OvR: Scores no calibrados (proporciones 70%-20%-10%)
Clase 1 (70%)
Clase 2 (20%)
Clase 3 (10%)
Hiperplano clase 1
Hiperplano clase 2
Hiperplano clase 3

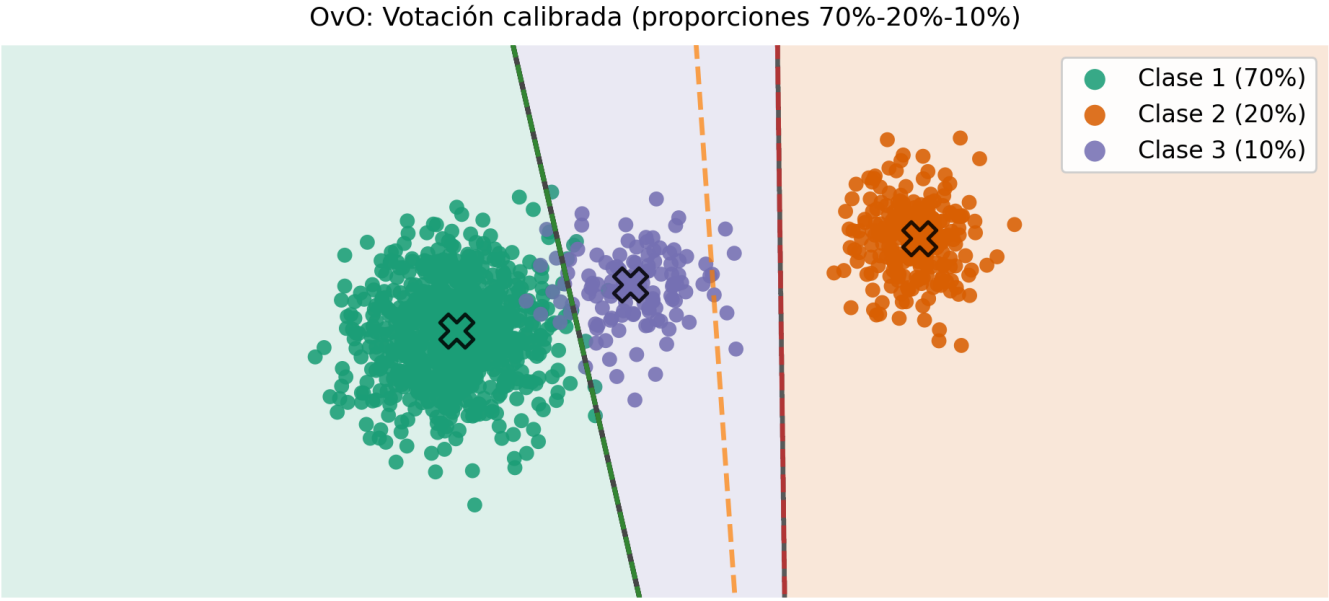
OvO: Votación calibrada (proporciones 70%-20%-10%)
Clase 1 (70%)
Clase 2 (20%)
Clase 3 (10%)

Formulación directa: SVM de Crammer–Singer

En lugar de entrenar múltiples clasificadores binarios, entrenamos un clasificador multiclase directamente.

- Para cada clase $j \in Y$, queremos una función de puntuación ξ_j dada por $\xi_j(x) = \langle w_j, x \rangle + b_j$ donde $w_j \in \mathbb{R}^d$ y $b_j \in \mathbb{R}$.

  Entonces, el clasificador vendrá dado por $f(x) = \arg\operatorname*{máx}_{j \in Y} \xi_j(x)$.

- Queremos minimizar la pérdida *hinge* multiclase:

$$\mathcal{E}_{\mathcal{D}} = \frac{1}{m} \sum_{i=1}^{m} \operatorname*{máx}_{j \neq y_i} \operatorname{máx} \left\{ 0, 1 + \xi_j(x_i) - \xi_{y_i}(x_i) \right\}.$$